Lab8　k-Means 应用实践

使用 Python 访问 Baidu Web 的 API，先用 Baidu Web 的 API 获得数据，然后用 kMeans 算法对地理位置进行聚类，并对聚类得到的簇进行后处理。代码文件：kmeans.py。

1. 获取地图数据

百度地图提供 API 的网址：

http://lbsyun.baidu.com/index.php?title=webapi/guide/webservice-placeapi

（1）注册成为开发者

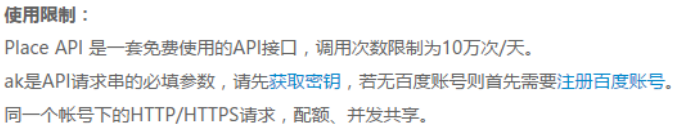

注册登录百度账号之后，点击获取秘钥，弹出注册成为开发者页面：

点击创建应用：

注意：IP 白名单中要填入访问方的公网 IP，查看 ip 白名单中的 ip 是否与本机 ip 一致，若不一致则改成本机 ip，这里是中大公网 IP。

应用类型选择服务端，可以看到下面有需要的 Place API v2 服务。点击确定就可以看到秘钥，如下（AK 部分）：

WangBianqin, Public Experimental Teaching Center (Guangzhou), Sun Yat-sen University

（2）使用 API 获取数据（api.py）

查看网页，了解 API 的使用格式。

API 的格式：

http://api.map.baidu.com/place/v2/search?q=查询内容&page_size=范围记录数量&page_num=分页页码&region=地区&output=数据格式&ak=秘钥

```
# 打开命令窗口，并切换至文件 api.py 所在目录

> python api.py
```

观察获得的数据和目录下的 Restaurant_Data_Beijing.txt 文件中保存的数据是一致的：

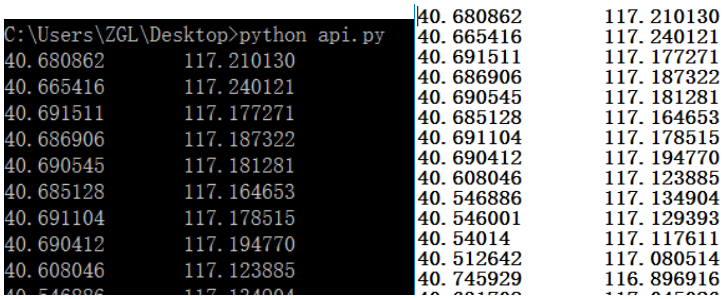

```
C:\Users\ZGL\Desktop>python api.py
40.680862       117.210130
40.665416       117.240121
40.691511       117.177271
40.686906       117.187322
40.690545       117.181281
40.685128       117.164653
40.691104       117.178515
40.690412       117.194770
40.608046       117.123885
```

```
40.680862       117.210130
40.665416       117.240121
40.691511       117.177271
40.686906       117.187322
40.690545       117.181281
40.685128       117.164653
40.691104       117.178515
40.690412       117.194770
40.608046       117.123885
40.546886       117.134904
40.546001       117.129393
40.54014        117.117611
40.512642       117.080514
40.745929       116.896916
```

2. kMean 算法实现

（1）建立辅助函数

函数 loadDataSet()读取文件的数据，函数 distEclud()计算两个向量的欧式距离，函数 randCent()随机生成 k 个随机质心。

```
>>> import kmeans
>>> from numpy import *
#从文本文件中构建矩阵：
>>> dataset = mat(kmeans.loadDataSet('testSet.txt'))
# 测试函数 randCent()：
>>> min(dataset[:, 0])
>>> min(dataset[:, 1])
>>> max(dataset[:, 1])
>>> max(dataset[:, 0])
#查看 randCent()能否生成 min 到 max 之间的值：
>>> kmeans.randCent(dataset, 2)
#测试距离计算函数：
>>>kmeans.distEclud(dataset[0], dataset[1])
```

2019-04-17

（2）kMean 算法实现

函数 kMeans()接受 4 个输入参数，只有数据集及簇的数目是必选参数，而计算距离和创建初始质心的函数都是可选的。

```
>>> dataset = mat(kmeans.loadDataSet('testSet.txt'))
#查看聚类结果：
>>> myCentroids, clustAssing = kmeans.kMeans(dataset, 4)
#参看迭代的次数及结果：
>>> myCentroids
```

```
>>> clustAssing
```

3. 用 kMeans 算法对地图上的点聚类

餐厅是一个城市的重要组成部分，在北京城内有不少餐厅，当今地政府想要建立 4 个餐厅管理服务点，对整个北京中的餐厅进行管理，但是无法确定管理服务点要建在哪里才比较合理？假设现在给出北京地区的一些饭店所在的经纬度，具体分布如下图所示。尝试利用 **kMeans** 依据饭店的分布，找其各部分的中心位置。

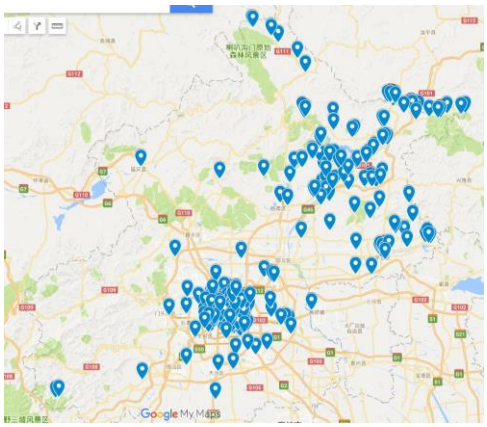

（1）准备数据

饭店的经纬度数据存放在 Restaurant_Data_Beijing.txt 文件中，其中每一行数据的第一列代表地点的纬度（北纬），第二列代表经度（东经）

```
>>> dataMat = loadDataSet('Restaurant_Data_Beijing.txt')
>>> dataMat
```

2019-04-17

（2）对地理坐标进行聚类

增加两个函数：函数 distSLC()返回地球表面两点之间的距离，函数 clusterPlaces ()将文本文件中的地点进行聚类并画出结果。

```
>>> kmeans.clusterPlaces(3)
```

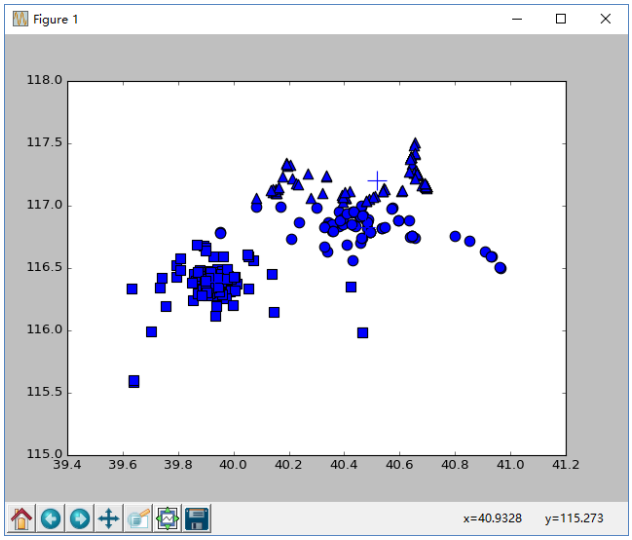

可以与 google map 里面的标记进行对比：

不同簇的数据点用不同的形状标记，+号所标注的就是对应簇的质心。可看到地点被大致分成 3 部分。依次修改 k 值为 4、5、6，观察相应的图像输出：

```
>>>kmeans.clusterPlaces(4)
>>>kmeans.clusterPlaces(5)
>>>kmeans.clusterPlaces(6)
```

4. 操作习题

（1）对聚类结果可视化（包含样本点和簇中心，用不同颜色、记号标记）。

（2）kmeans.py 中的语句“from numpy import * ”用语句“import numpy as np”代替，修改其中对应的代码，使其能够正常执行。

（3）尝试用 DBSCAN 聚类该数据集。（扩展）

（4）利用轮廓系数评估 kMeans 和 DBSCAN）对该数据集的聚类效果。（扩展）

（5）尝试在 Tensorflow 环境下实现 kMeans。（扩展）

2019-04-17